Analiza wydajności ruchu internetowego

Mikołaj Kużownik
Tomasz Marek

1. Wykorzystane narzędzia

1. Przetwarzanie danych
- pandas - wczytywanie danych z pliku, selekcja kolumn, czyszczenie braków, filtrowanie outlinerów i agregacja danych
- numpy - wykorzystane do szybkich obliczeń, np. wyliczenie pierwiasta z RMSE
1. Wizualizacja danych
- matplotlib.pyplot - definiowanie osi, tytułów, legend i siatek oraz zapis wykresów do plików png
- seaborn - generowanie wykresów
1. Uczenie maszynowe i modelwanie (scikit-learn)
- podział danych na zbiór treningowy i testowy
- implementacja i trenowanie algorytmów predykcyjnych
- wyliczanie metryk, takich jak MAE, RMSE oraz R^2

2. Zrozumienie biznesowe

Celem analizy jest ocena wydajności ruchu internetowego w USA na podstawie pomiarów FCC (Federalna Komisja Łączności). W zadaniu badamy:

1. rozkład prędkości pobierania (download) i wysyłania (upload) danych,
2. zależności między parametrami wydajności,
3. zmiany wydajności między rokiem 2021 a 2023,
4. możliwość predykcji prędkości download na podstawie dostępnych danych.

3. Przygotownie danych

1. Wczytano pliki z predkością pobierania i wczytywania dla roku 2021 i 2023.
2. Dokonano selekcji kolumn (wybrano kolumny ‘id’, ‘bytes_sec’, ‘dtime’.
3. Przeliczono bajty/s na megabajty/s.
4. Dokonano konwersji kolumny ‘dtime’ aby wyodrębnić godzinę pomiaru i dzień tygodnia.
5. Dokonano agregacji danych: obliczono średnie prędkości download i upload dla każdego użytkownika.

```
Download: 724,511 pomiarów, 4,302 użytkowników
Upload:   722,118 pomiarów, 4,301 użytkowników
Zagregowano dane dla 4,297 użytkowników.
```

3.1 Sprawdzenie brakujących, niespójnych wartości i outlinerów

1. Podczas sprawdzania braków danych wykazano, że nie ma pustych wartości w latach 2021 i 2023.
2. Do wykrywania outlinerów użyto metodę IQR (rozstęp ćwiartkowy). Wykryto 682 wartości odstających w 2023 roku oraz 1314 w roku 2021.
3. W latach 2023 wykryto 2 niespójne rekordy, natomiast w latach 2021 wykryto takich rekordów 6. Za niespójne rekordy uznano takie w których wartość pobierania lub wysyłania wyniosła <= 0 Mbps lub > 1000 Mbps.

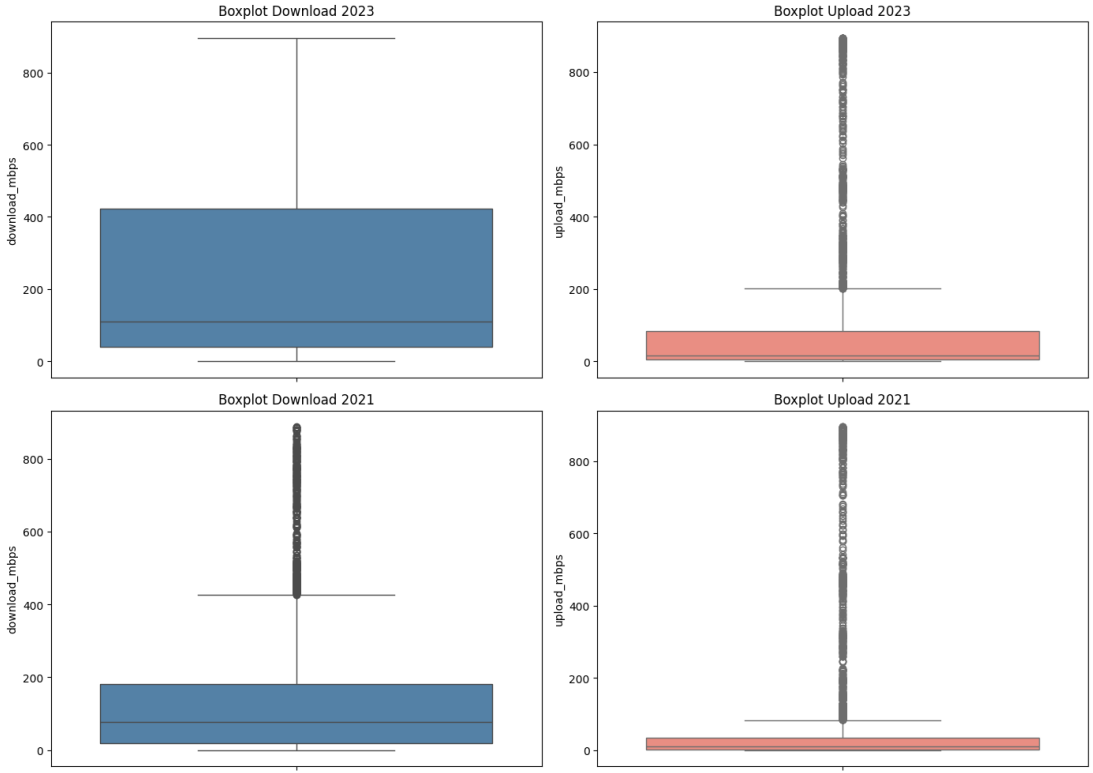

3.2 Usuwanie niespójnych wartości i przegląd outlinerów

1. Po usunięciu niespójnych wartości, pozostało 4295 rekordów w 2023 roku oraz 5281 w 2021.
2. Outlinerów nie usuwano, ponieważ były one tylko wartościami odstającymi od średnich wyników. Wypisano tylko klika przykładów.

```
=== Przykładowe outliery Upload 2023 (pierwsze 5) ===
     unit_id  upload_mbps
435    26477   337.559106
438    26515   338.467454
443    26583   315.438648
444    26595   224.062216
446    26607   339.980216
```

```
=== Przykładowe outliery Download 2021 (pierwsze 5) ===
      unit_id  download_mbps
935    214176     434.448033
1048   244804     455.876142
1094   598598     432.708853
1288   658226     434.132151
```

3.3 Podstawowe statystyki

Wyznaczono podstawowe statystyki:

mean - średnia arytmetyczna

std - odchylenie standardowe

min - minimum

25% (1 kwartyl) - wartość poniżej której znajduje się 25% wyników

50% (2 kwartyl)

75% (3 kwartyl)

max - maximum

```
=== Statystyki opisowe – Download 2021 [Mbps] ===
count    5287.00
mean      139.81
std       177.78
min         0.00
25%        19.41
50%        77.86
75%       181.83
max       887.52
Name: download_mbps, dtype: float64

=== Statystyki opisowe – Upload 2021 [Mbps] ===
count    5287.00
mean       66.48
std       168.36
min         0.00
25%         1.68
50%         9.30
75%        34.38
max       894.42
Name: upload_mbps, dtype: float64
```

```
=== Statystyki opisowe – Download 2023 [Mbps] ===
count    4297.00
mean      257.96
std       280.55
min         0.00
25%        38.90
50%       110.32
75%       422.75
max       896.14
Name: download_mbps, dtype: float64

=== Statystyki opisowe – Upload 2023 [Mbps] ===
count    4297.00
mean      111.94
std       225.10
min         0.00
25%         4.90
50%        16.51
75%        83.30
max       894.31
Name: upload_mbps, dtype: float64
```

4.1 Eksploracja danych - Porównanie 2021 vs 2023

Porównanie średnich prędkośći download oraz upload między 2021 r. i 2023r.

Wniosek:
Wydajność Internetu znacząco wzrosła w analizowanym okresie.

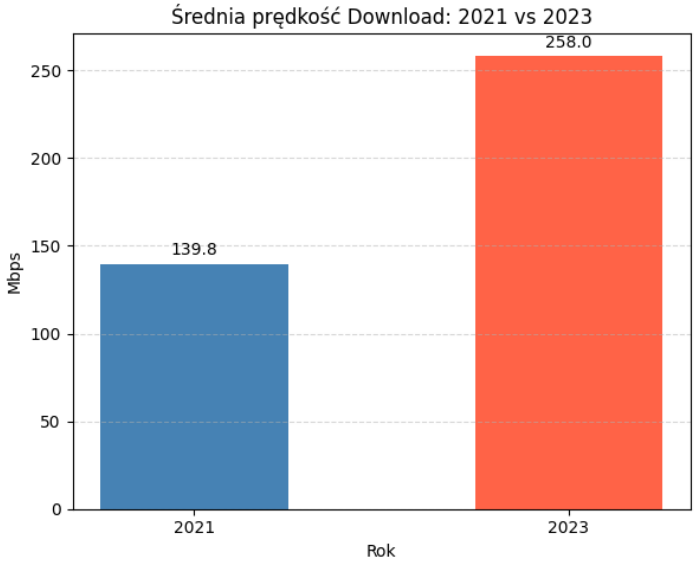

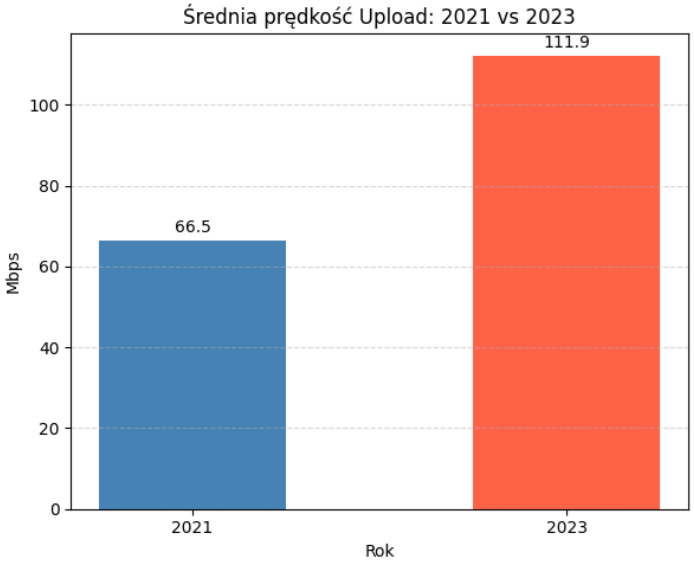

4.2 Eksploracja danych - Zmienność w ciągu dnia

Prędkość Internetu zmienia się w zależności od pory dnia.najwyższe wartości: ~7:00, ~13:00, ~19:00

niższe wartości: noc i późny wieczór

Wniosek: Wydajność zależy od obciążenia sieci.

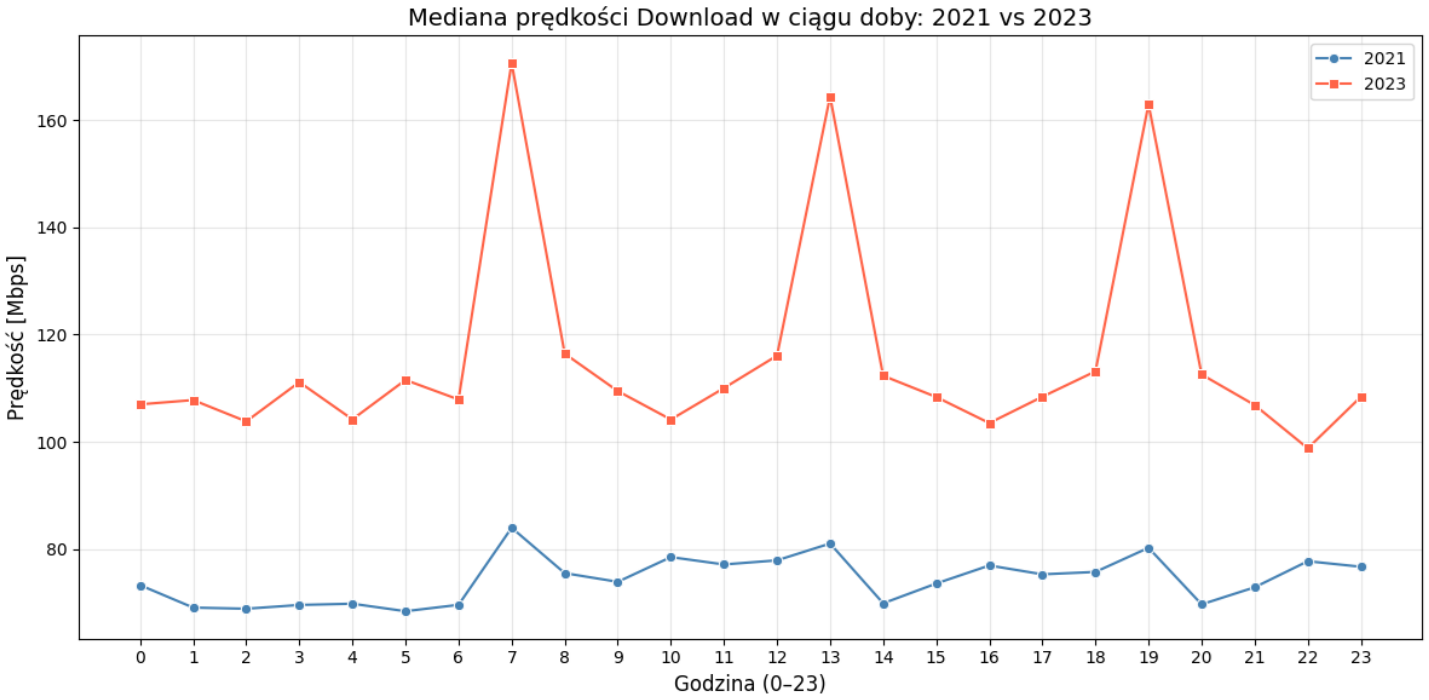

4.3 Eksploracja danych - Dzień tygodnia vs godzina

Analiza pokazuje powtarzalne wzorce w ciągu dnia.

Wniosek: dzień tygodnia ma niewielki wpływ

główny czynnik: godzina

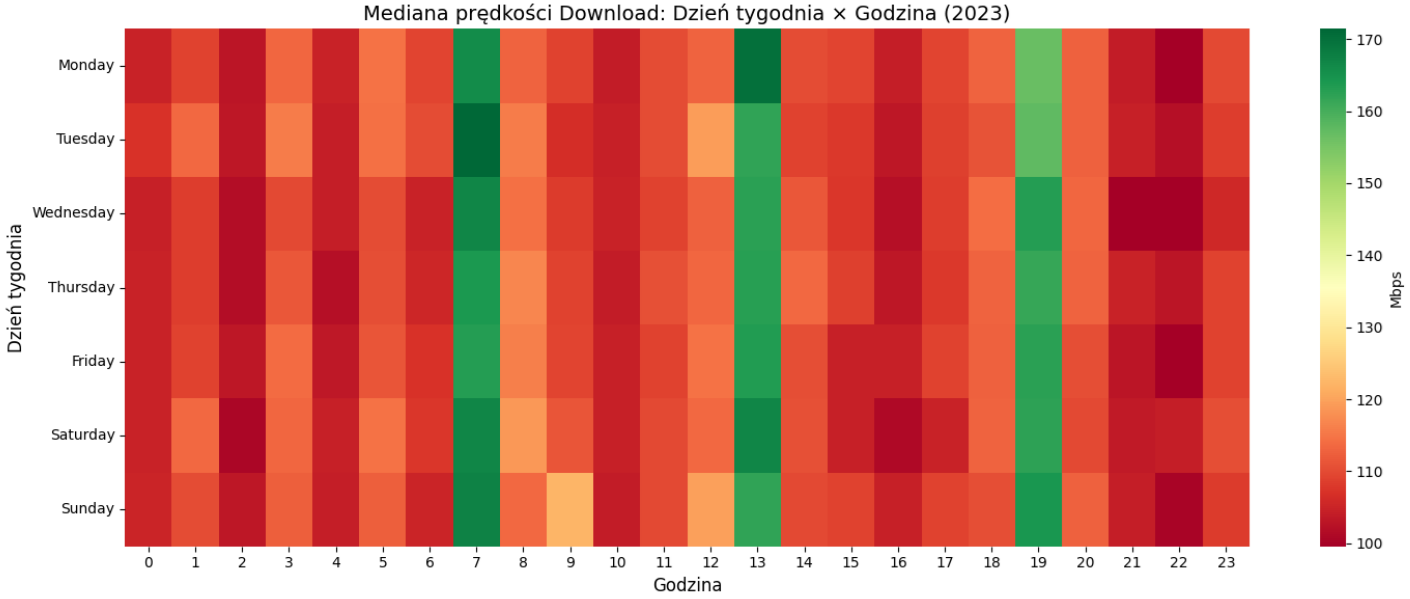

4.4 Eksploracja danych - Rozkład prędkości

Rozkład prędkości jest asymetryczny.

mediana ~110 Mbps

średnia ~258 Mbps

obecność wartości ekstremalnych

Wniosek:
Dane są silnie zróżnicowane i zawierają outliery.

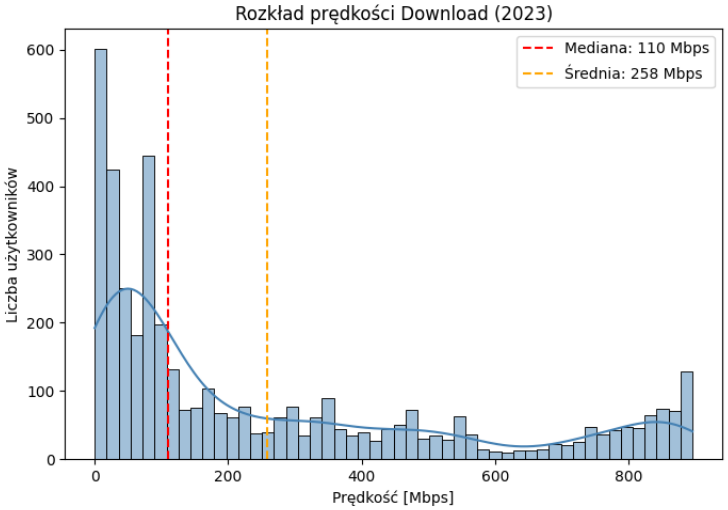

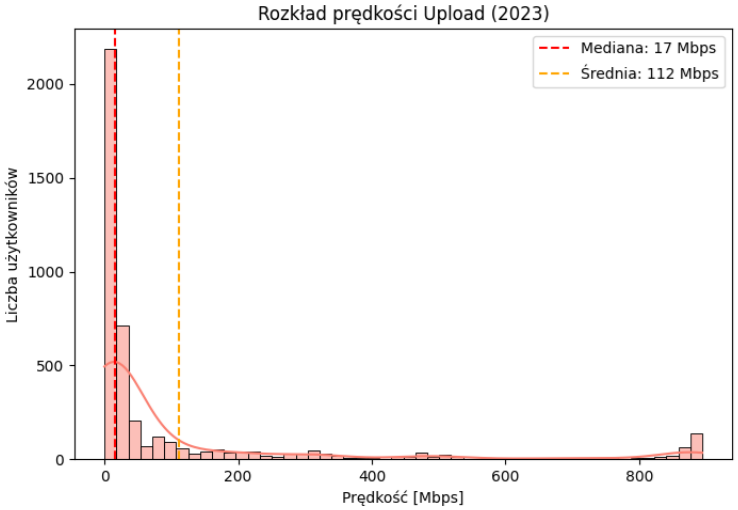

5.1 Modeling - Problem predykcji

Cel:
Celem było przewidzenie prędkości download.

Zmienne wejściowe:
- upload
- godzina
- dzień tygdnia

Modele:
- regresja liniowa
- random forest
- gradient boosting

5.2 Modeling - Zastosowane modele predykcyjne

Regresja liniowa
- prosty model
- zakłada liniową zależność

Random Forest
- wiele drzew decyzyjnych
- odpornosc na szum

Gradient Boosting
- model iteracyjny
- wysoka dokładność

5.3 Modeling - Wyniki modeli

Ocena modeli:
Model uznajemy za najlepszy, jeśli:
ma wysokie R^2 (lepsze dopasowanie)
ma niski MAE i RMSE (mniejsze błędy)

Wyniki:
Random Forest – najwyższe R^2 (~0.72), najniższe MAE i RMSE
Gradient Boosting – bardzo podobne wyniki
Regresja liniowa – najsłabsza

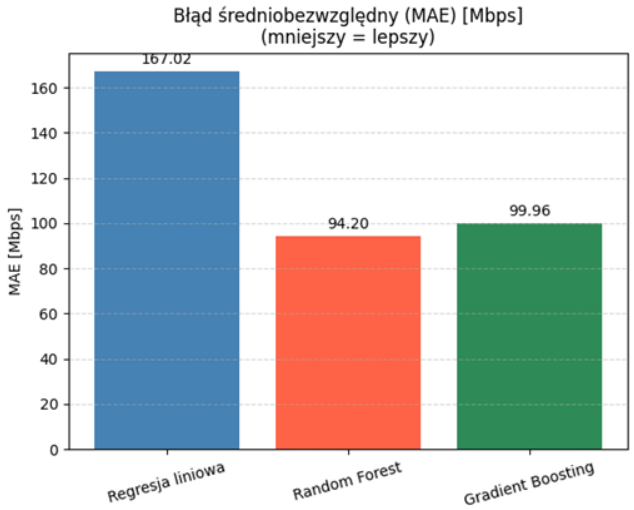

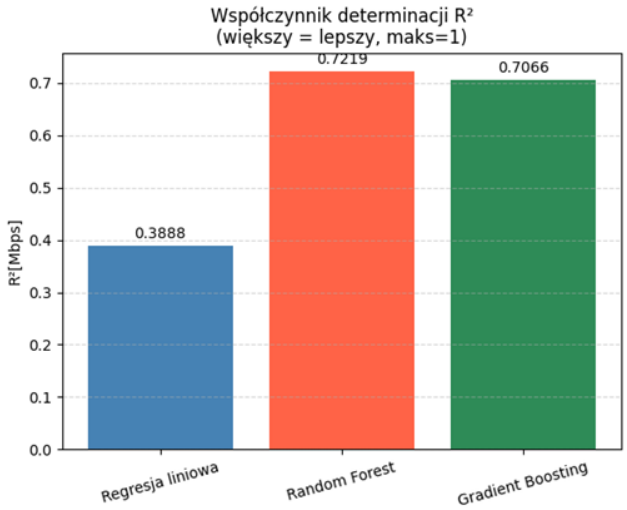

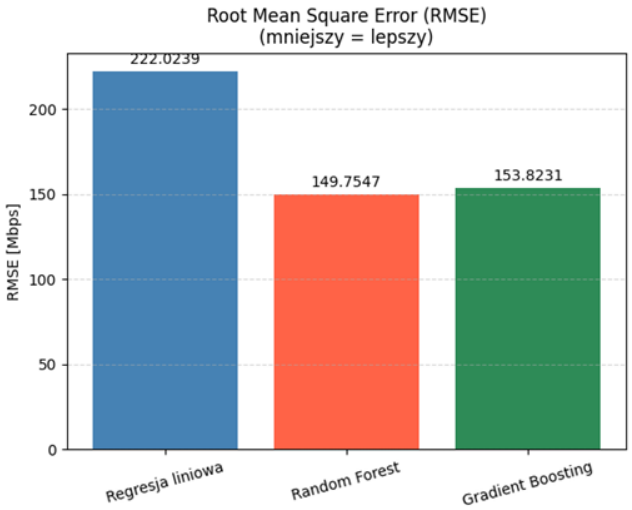

6.1 Ewaluacja - Predykcja vs rzeczywistosc

Obserwacje:
Regresja liniowa- duży rozrzut, słabe dopasowanie
Random Forest - punkty blisko linii (najlepszy)
Gradient Boosting - dobre dopasowanie

Wyniki:
Random Forest – najwyższe R^2 (~0.72), najniższe MAE i RMSE
Gradient Boosting – bardzo podobne wyniki
Regresja liniowa – najsłabsza

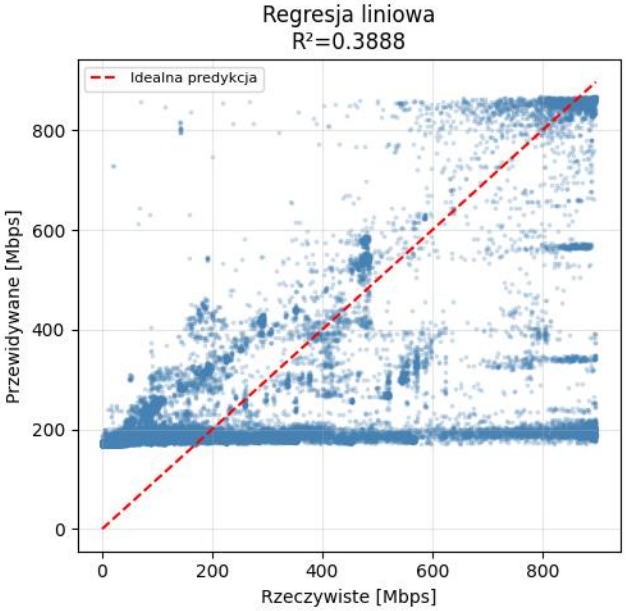

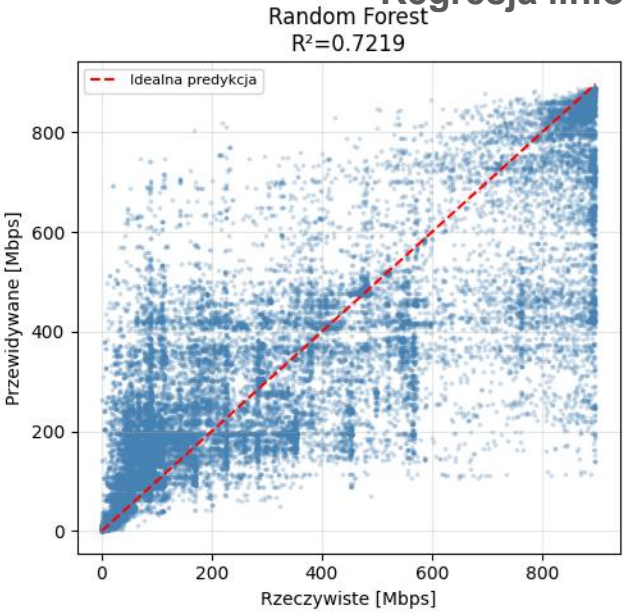

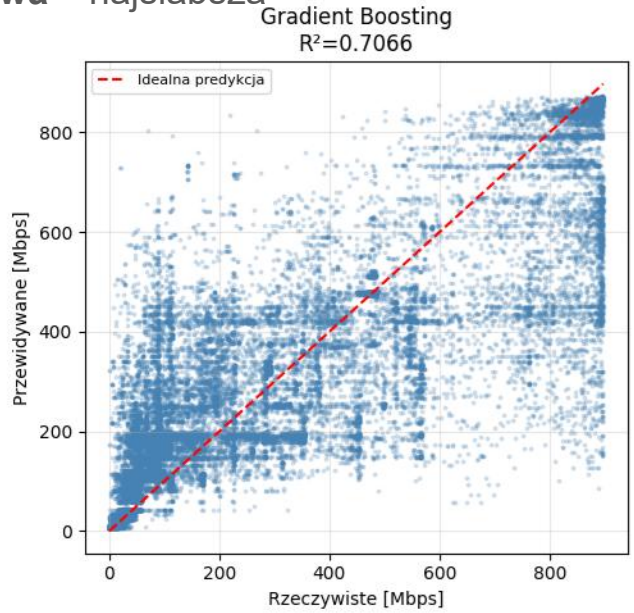

6.2 Ewaluacja - Ważność cech

Interpretacja:
- model opiera się głównie na upload
- pozostałe cechy maja małe znaczenie

Wniosek
- upload jest kluczowym predyktorem prędkości downlod

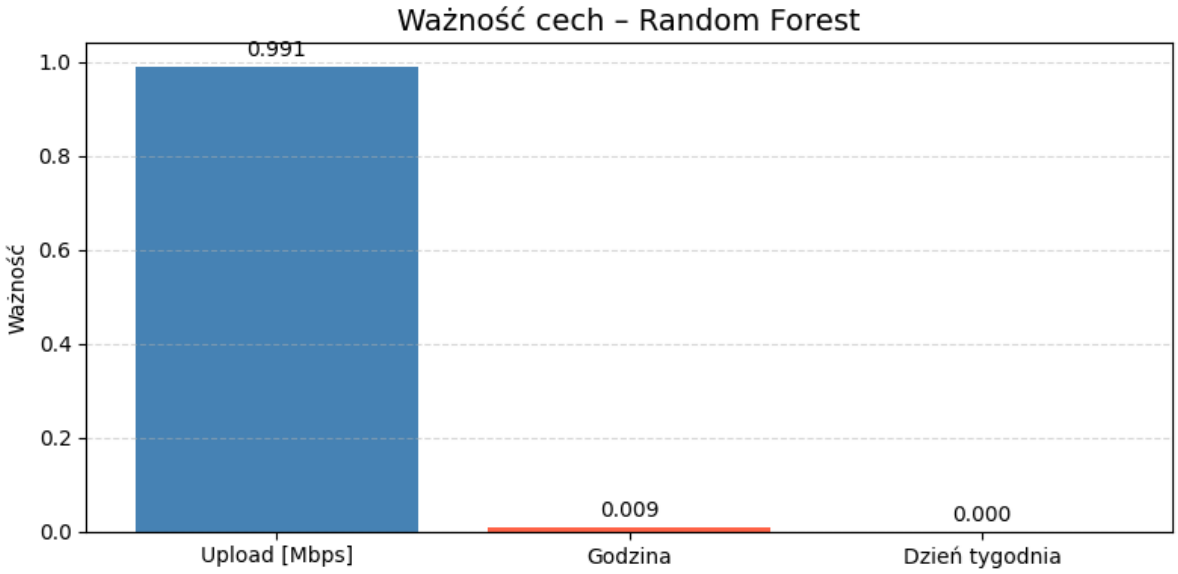

7. Wnioski dotyczące danych

- Zauważalna jest znacząca poprawa jakości usług. Średnia prędkość pobierania wzrosła z 139.81 Mbps w 2021 roku do 257.96 Mbps w 2023 roku. Jest to poprawa o niemal 85% w 2 lata, dowodzi to o inwestycji w modernizację infrastruktury telekomunikacyjnej w USA.
- Rozkład prędkości jest bimodalny - wyraźnie widać dwie grupy użytkowników: z wolnymi łączami (<100 Mbps) i szybkimi (>800 Mbps).
- W ciągu doby przez większość czasu widać niewielkie wahania, jednak prędkość jest zdecydowanie wyższa o godzinie 7, 13 oraz 19. Może to wskazywać na momenty odpoczynku od sieci, takie jak dojazd i powrót z pracy lub lunch.
- Wzorzec godzinowy jest podobny w obu latach.
- Prędkość nie zmienia się istotnie między dniami tygodnia - sieć jest stabilna przez cały tydzień. Nawet w weekendy, gdy natężenie sieci jest wyższe, infrastruktura dysponuje wystarczającym zapasem pojemności, aby nie dopuścić do obniżenia prędkości transferu.

7.1 Wnioski dotyczące predykcji

- Najwyższą skuteczność osiągnął model Random Forest. Charakteryzując się najniższym błędem MAE (94.20 Mbps) i RMSE (149.75 Mbps) oraz najwyższym współczynnikiem determinacji R^2 (0.72).
- Modele drzewiaste (Random Forest oraz Gradient Boosting) osiągnęły współczynniki powyżej wartości 0.7, co oznacza co oznacza, że potrafią one wyjaśnić ponad 70% zmienności prędkości pobierania na podstawie zaledwie trzech zmiennych wejściowych (upload, godzina, dzień tygodnia).
- Analiza ważności cech wykazała, że model opiera się niemal wyłącznie na prędkości wysyłania. Choć ogólna wydajność sieci waha się w ciągu doby, z perspektywy algorytmu te spadki są zbyt małe w zestawieniu z ogromnymi różnicami w przepustowości.
- Prędkość Upload okazała się najsilniejszym predyktorem dla wartości pobierania. Wynika to z faktu, że obie te wartości są determinowane przez pakiet wykupiony przez abonenta.